

LUCIANO JESUS QUIROZ GONZALES

QUIROZ-LACERNA-TRABAJO DE INVESTIGACION-solocontenido.pdf

 Universidad Señor de Sipan

Detalles del documento

Identificador de la entrega

trn:oid:::26396:459381182

Fecha de entrega

14 may 2025, 11:27 p.m. GMT-5

Fecha de descarga

20 may 2025, 7:13 p.m. GMT-5

Nombre de archivo

QUIROZ-LACERNA-TRABAJO DE INVESTIGACION-solocontenido.pdf

Tamaño de archivo

1.2 MB

23 Páginas

4379 Palabras

24.572 Caracteres

52 % detectado como IA

El porcentaje indica la cantidad de texto calificado en la entrega que probablemente se generó usando IA.

Precaución: Se requiere revisión.

Es esencial comprender los límites de la detección de IA antes de la toma de decisiones acerca del trabajo del estudiante. Lo alentamos a obtener más información acerca de las funciones de detección de IA de Turnitin antes de usar la herramienta.

Aviso legal

Nuestra evaluación de escritura con IA está diseñada para ayudar a los educadores a identificar texto que podría haberse creado con una herramienta de IA generativa. Nuestra evaluación de escritura con IA puede no ser precisa en todos los casos (existe la posibilidad de identificar erróneamente texto humano como generado con IA y probablemente generado como texto creado por humanos), por lo que no debería usarse como la única prueba para tomar acciones adversas contra un estudiante. Se necesita mayor escrutinio y criterio humano junto con la aplicación de la organización de las políticas académicas específicas de la institución para determinar si se ha incurrido en alguna mala conducta académica.

Preguntas frecuentes

¿Cómo debería interpretar los falsos positivos y el porcentaje de escritura con IA de Turnitin?

El porcentaje mostrado en el informe de escritura con IA es la cantidad del texto calificado en la entrega que el modelo de detección de escritura con IA de Turnitin determina si un texto se generó probablemente con IA desde un modelo de lenguaje grande.

Los falsos positivos (que marcan incorrectamente alertas de texto escrito por humanos como generado con IA) son una posibilidad en los modelos de IA.


Los puntajes de detección de IA inferiores a 20 %, que no aparecen en informes, tienen una mayor probabilidad de falsos positivos. Para reducir la probabilidad de malinterpretación, no se atribuye ningún puntaje o resultado y se indican con un asterisco en el informe (*%).

El porcentaje de escritura de IA no debe ser el fundamento para determinar si ha ocurrido una mala conducta. El revisor/instructor debería usar el porcentaje como un medio para iniciar una conversación formativa con sus estudiantes y/o usarlo para examinar el ejercicio enviado según las políticas de la escuela.

¿Qué significa 'texto calificado'?

Nuestro modelo solo procesa el texto calificado en el formato de escritura de formato largo. La escritura de formato largo significa que los enunciados individuales en párrafos que constituyen una parte más grande del trabajo escrito, como un ensayo, una disertación, un artículo, etc. El texto calificado que se ha determinado que se generó probablemente con IA se resaltará en color cian en la entrega.

El texto no calificado, como viñetas, bibliografías comentadas, etc., no se procesará y puede crear disparidad entre los puntos destacados del envío y el porcentaje mostrado.



QUIROZ_LACERNA_TRABAJO DE INVESTIGACION (1)

Archivo

Editar

Ver

Insertar

Formato

Herramientas

Extensiones

Ayuda

100%

Texto nor...

Arial

12

+

-

+

-

+

😊

📎

12%

Overall Similarity

Last checked: May 14 10:26 PM -05

What should I do with my score?

1

www.coursehero.com

INTERNET

2%

2

Instituto Madrileno de F...

SUBMITTED WORK

1%

You can run 2 more similarity checks.

📊

📊

📊

Run New Similarity Check

View Full Report

How should I use these checks?

Resumen

Este estudio analiza el impacto del procesamiento de lenguaje natural (PLN) en el ámbito sanitario, evaluando las técnicas más eficaces para mejorar procesos y servicios médicos. La investigación utiliza una revisión sistemática basada en el protocolo PRISMA 2020, seleccionando 20 artículos clave de bases de datos académicas como IEEE Xplore y ScienceDirect. Se identifican cuatro técnicas principales: análisis de sentimientos, reconocimiento de entidades nombradas, clasificación automática de textos y generación de resúmenes. Estas técnicas han demostrado ser herramientas efectivas para mejorar la precisión diagnóstica, optimizar la gestión de datos clínicos y reducir la carga administrativa.

El análisis revela que los modelos avanzados de aprendizaje profundo, como BERT y CNN, logran tasas de precisión superiores al 90% en tareas como la

Página 3 of 25 - Entrega de escritura con IA

Identificador de la entrega trn:oid:::26396:459381182

I. }INTRODUCCIÓN

1.1. Realidad Problemática

Al cruzar hacia el sector de la salud, también nos enfrentamos a una serie de desafíos como resultado de la creciente demanda de atención médica, la mejora en los servicios médicos y la urgencia de aumentar la eficiencia en las tareas administrativas y de cuidado. En este complicado contexto, destaca la necesidad apremiante de optimizar la gestión de la información y este examen de datos de diversas fuentes, como registros médicos electrónicos, informes de salud, datos de pacientes y documentos científicos. Para garantizar diagnósticos precisos, decisiones clínicas racionales y la provisión de servicios de calidad, es crucial asegurarse de que haya precisión en la interpretación y que la información sea procesada adecuadamente. Sin embargo, la conducción y análisis manual de tales grandes volúmenes de datos no solo conduce a procedimientos ineficientes, sino que también multiplica las probabilidades de error humano, lo que afecta negativamente la calidad de los servicios sanitarios y la seguridad para los pacientes [1].

Recientemente, el PLN se ha vuelto una herramienta básica para enfrentar esos retos. Hay que destacar impresionante el desarrollo que ha tenido la medicina con el PLN, gracias a la posibilidad de las máquinas a entender y a hacer un análisis del lenguaje humano. Permitiendo actuar con textos médicos, extracción de datos, categorización de diagnósticos o comunicación entre los sistemas de forma automatizada. Desde su utilización por parte de enfermeras para la interpretación de textos médicos, al diseño de herramientas decidir de mejora en la salud, el rango de aplicación de PLN es increíblemente amplio. La eficacia de estos avances tecnológicos se ha evidenciado al disminuir el volumen de gestiones administrativas que los especialistas médicos deben llevar a cabo, mejorar la exactitud al momento de diagnosticar y al agilizar el acceso pertinente a la información [2] [3].

Aunque el PLN se vea como una herramienta tecnológica poderosa, los programas de ordenadores que interpretan el habla se ven abrumados por un sin fin de retos específicos del contexto del habla de ámbitos como la

medicina, tal como el problema de los registros poco claros o los tiempos

técnicos especializados. Este tipo de sistemas tiene una difícil inclusión en el sistema de salud, en particular porque muchos hospitales y clínicas utilizan diferentes tipos de tecnologías que no se comunican entre sí [4]. Sin embargo, sería interesante toparse con una estrategia que utilizara los mejores métodos de PLN en esta fase, y así mejorar la calidad de atención médica y superar los existentes. Además, de esta forma podrías obtener más provecho de estas tecnologías.

Mediante distintas investigaciones se ha buscado información sobre las utilidades del PLN en dicho ámbito, centrando todo en la extracción automática de datos médicos, la mejora de la intercomunicación entre los especialistas de la salud y la optimización de la informática en las instituciones sanitarias [5]. Investigaciones recientes destacan que las estrategias de PLN orientadas a diferentes tipos de aprendizaje profundo han progresado en clasificar documentos hipotensos y en el hallazgo de datos en historias clínicas. Lo que resulta innegable, sin embargo, es que existen trabajos considerables en precisión, posibilidad de crecimiento y uso en diferentes contextos clínicos. [6]

Integrar métodos avanzados de PLN en los procesos sanitarios tiene el potencial no sólo de aumentar la efectividad administrativa e igualmente perfeccionar la atención al cliente desde la etapa de prevención hasta el tratamiento y seguimiento. Sin embargo, ha habido avances, pero todavía falta por hacer más en la investigación en torno a estas tecnologías de estos temas con el fin de reforzar la calidad del servicio y disminuir los costos. La presente revisión sistemática tiene como principal objetivo consolidar todo lo relacionado al estado actual del uso PLN en el sector salud, su finalidad es actuar como insumo para el desarrollo de futuras investigaciones y aplicaciones en este campo al tratar de establecer cuáles son las técnicas que más resultado han dado y evaluarlas con el objetivo de determinar cuáles son los métodos que se consideran más efectivos para el sector [7].

1.2. Formulación del Problema

La gestión efectiva de datos de salud como notas médicas, registros médicos electrónicos y datos de laboratorio es importante para la mejora de los procesos clínicos y administrativos. Aún con los avances en tecnología, la gestión de datos no estructurados sigue siendo un desafío. Hay suficiente evidencia de que el Procesamiento de Lenguaje Natural tiene un potencial significativo para aumentar las eficiencias operativas y corregir desafíos con la calidad de la atención a la persona a través del uso de datos informativos sin estructurar. Dentro del área de PLN, existen varias técnicas y enfoques que varían en efectividad y aplicación. Es imperativo explorar las metodologías de PLN que tienen el mayor impacto en la mejoría de procesos y servicios en el sector sanitario.

Como resultado, se cuestiona lo siguiente: **¿Qué técnicas o métodos de PLN han tenido un mayor efecto en la mejoría de procesos y servicios en el ámbito sanitario, y cuáles son las áreas emergentes que necesitan más atención para que funcionen correctamente?**

1.3. Hipótesis

Este tipo de metodologías, junto al uso de herramientas avanzadas que implican un aprendizaje profundo e incluso redes neuronales, se entienden como una forma innovadora y eficaz para fomentar la mejoría de procesos y servicios en el ámbito de la sanidad, por tanto se trata de una herramienta que fácilmente supera los métodos rutinarios en términos de precisión, eficiencia, y de implantación en distintos tipos de contexto asistencial y, por consiguiente, deben ser priorizadas en el trabajo de investigación.

1.4. Objetivos

1.4.1. Objetivo General

Analizar y comparar las técnicas de PLN aplicadas en el ámbito sanitario, evaluando su impacto en la mejoría de procesos y servicios médicos.

1.4.2. Objetivos Específicos

- a) Selecciona y analiza artículos académicos relevantes que se

centren en aplicaciones biomédicas de técnicas de PNL.

- b) Examinar y clasificar las principales técnicas de procesamiento de lenguaje natural utilizadas en el sector salud.
- c) Evaluar el impacto de las técnicas de PLN en la mejoría de la toma de decisiones clínicas y la gestión de la información médica.
- d) Comparar la efectividad de las técnicas de PLN en diferentes áreas del ámbito sanitario.

1.5. Teorías relacionadas al tema

1.5.1. Procesamiento de Lenguaje Natural (PLN)

PLN se centra en la correlación que existe entre las computadoras y el lenguaje humano. Esta área ha evolucionado significativamente debido al crecimiento del aprendizaje automático y el aprendizaje profundo. Como se mencionó anteriormente, PLN permite a las máquinas entender, interpretar y producir lenguaje humano según se requiere en la automatización de tareas como la traducción automática, el análisis de sentimientos y la extracción de información. En el cuidado de la salud, ha sido vital para mejorar la interpretación de registros médicos electrónicos, diagnósticos automáticos y para fomentar una mejor comunicación entre pacientes y médicos utilizando asistentes virtuales y chatbots [8].



Figura 1. Procedimiento del Lenguaje Natural.

Fuente: [9]

Técnicas de Procesamiento de Lenguaje Natural en la Salud

Análisis de sentimientos

El destilado de sentimientos es un proceso que permite discernir las emociones y opiniones que un texto expresa, lo que resulta fundamental. Asimismo, en los sistemas tomados por la salud, esta técnica se aplica en la verificación en que los pacientes a los que se les ha enviado el encuesta responden, la recopilación de las revisiones de interés de la sanidad, o en aquellas partes donde ellos escriben sus registros médicos dejando comentarios y opiniones sobre un caso clínico. Es necesario determinar el nivel de satisfacción de los pacientes, los primeros signos de inquietud o de predominio emocional o psicológico entre muchas otras acciones para mejorar la atención en las entidades sanitarias. La aplicación estudia textos que luego son divididos y califican en positivos, negativos y neutros mediante la aplicación de algoritmos de aprendizaje y redes neuronales avanzadas [10].




Figura 2. Las principales técnicas utilizadas en el análisis de sentimiento.

Fuente: [10]

Reconocimiento de Entidades nombradas (NER)

El NER o el reconocimiento de entidades nombradas es un método del PLN que se emplea en el sector salud, para reconocer y clasificar entidades dentro de los textos médicos, como, por ejemplo: nombres de enfermedades, medicamentos, síntomas, procedimientos y fechas. Esto hace posible, convertir textos complejos a datos estructurados que luego puedan ser procesados para facilitar la toma de decisiones clínicas o construcción de repositorios enfermedades. Modelos más modernos como BERT o Transformers permiten realizar NER con buena precisión mejorando el sistema de información de salud en tiempo real [11].




Figura 3. Categorización de NER en métodos clínicos.

Fuente: [11]

Resumen Automático de Textos

La resumición automática de textos es una herramienta impresionante y puede resultar beneficiosa en el campo de la salud, al revisar largos documentos médicos. Sintetiza vastas informaciones en versiones más pequeñas y comprensibles [12]. Al igual que con cualquier tecnología moderna de vanguardia, los campos de los transformadores neuronales y la resumición automática de textos están cada vez más interconectados. Su sinergia combinada permite un medio más directo y preciso para transmitir una idea, en el cual se forma un único clon único. Permite que el equipo relevante, ya sea un investigador o un médico, haga un vistazo rápido a un informe en lugar de pasar una cantidad significativa de tiempo leyendo todo el informe. En lugar de repasar un informe, los usuarios pueden extraer y recuperar la información necesaria con facilidad, lo que les permite tomar decisiones únicas más informadas sin esfuerzo [13].




Figura 4. Resumen de texto en PLN.

Fuente: [14]

1.5.2. Redes Neuronales y Aprendizaje Profundo

El aprendizaje profundo, una técnica avanzada de aprendizaje automático que explota redes neuronales profundas, ha sido central en el progreso del PLN y la minería de datos médicos. En contraste con las prácticas habituales de los algoritmos de aprendizaje automático,

el aprendizaje profundo mejora enormemente el rendimiento de tareas complejas sin intervención humana en grandes cantidades de datos no estructurados, como imágenes médicas, informes textuales y datos de series temporales. En medicina, los algoritmos de aprendizaje profundo se utilizan en diagnósticos por imagen, como la localización de tumores en radiografías y resonancias magnéticas, así como para procesar automáticamente los registros médicos para ayudar en la toma de decisiones de los clínicos [15].

Por ejemplo, las redes neuronales convolucionales (CNN) se han convertido en una herramienta popular para la evaluación automatizada de fotografías de imágenes médicas, mientras que arquitecturas basadas en transformadores como BERT y GPT han mejorado las formas en que el procesamiento del lenguaje natural (NLP) se integra en la comprensión del texto clínico. Con estas mejoras, se hizo más fácil crear sistemas de soporte a la decisión clínica que brindan recomendaciones específicas para los pacientes basados en datos clínicamente relevantes en los sistemas en funcionamiento, aumentando así la eficiencia de los sistemas de salud y la calidad de la atención ofrecida [16].




Figura 5. Arquitectura de una CNN.

Fuente: [17]

Modelo neuronal de McCulloch-Pitts

Primero, Warren McCulloch, quien era psiquiatra además de neuroanatomista, y Walter Pitts, un matemático, lograron producir una función rudimentaria en el año 1943. Su proyecto conjunto nos brinda nuestro primer plano para una neurona artificial. Según las palabras de Gil Rubio, Cruz Pérez y Perdomo Charry [18]. Según se ilustra en la figura 6, un modelo neuronal con n entradas incluye:

- Una serie de entradas $X_1, X_2 \dots X_n$
- Los pesos sinápticos $W_1, W_2 \dots W_n$ se relacionan con cada una de las entradas.
- Una función de agrupación, Σ
- Una función de activación, f
- Una salida, Y




Figura 6. Modelo Neuronal de McCulloch-Pitts.

Fuente: [18]

1.5.3. Aprendizaje Automático

Dentro del vasto mundo de la Inteligencia Artificial se encuentra el fascinante campo del Aprendizaje Automático (Machine Learning), el cual permite a las máquinas adquirir sabiduría y llevar a cabo funciones sin requerir una programación directa. En vez de dictar reglas específicas para llevar a cabo una tarea, los sistemas de Aprendizaje Automático tienen la habilidad de

aprender y perfeccionar su rendimiento de forma autónoma al estudiar datos, adaptándose y mejorando a medida que reciben más información [19].




Figura 7. Procedimiento de trabajo del Aprendizaje Automático.

Fuente: [18]

Aprendizaje supervisado

A medida que el tamaño de un conjunto de datos se obtiene se consigue mayor probabilidad de que el algoritmo adquiriera un entendimiento de una temática en específico, esto se aplica al aprendizaje supervisado, en donde el algoritmo es guiado por datos ya etiquetados y con las respuestas correctas, como se visualiza en la figura 6. Al término del entrenamiento, el algoritmo que en el aprendizaje ya no usará las etiquetas de las respuestas correctas, se le proporcionará diferente información donde el algoritmo habrá tenido la capacidad de anticipar la respuesta a la pregunta [18].

Aprendizaje no supervisado

Los algoritmos no supervisados se basan en un conjunto de datos carente de etiquetas o clases que se puedan utilizar para el entrenamiento. En otras palabras, no hay información previa sobre ninguna variable que pueda predecir o tener un resultado, ya sea de naturaleza categórica o numérica. En general, como se ilustra en la figura 8, el aprendizaje no supervisado se basa en actividades de agrupación. El objetivo principal es descubrir grupos de datos que son equivalentes mientras son disímiles entre sí [18].




Figura 8. Aprendizaje no supervisado

Fuente: [18]

1.5.4. Desafíos y Oportunidades del PLN en el Sector Sanitario

ML y PLN han hecho progresos significativos en el cuidado de la salud, pero todavía hay muchos obstáculos que dificultan su implementación en entornos clínicos de la vida real. Uno de los mayores desafíos es la calidad de los datos y la interoperabilidad. Un buen número de sistemas de información médica aún dependen del uso de formatos de datos no estructurados o incluso conjuntos de datos incompletos, lo que inhibe el entrenamiento de modelos precisos. Además, la implementación de estas tecnologías también implica que los especialistas sanitarios deben ser capacitados adecuadamente para usarlas, lo que presenta desafíos en relación con la capacitación y el cambio organizacional [20].

A pesar de estos obstáculos, hay un potencial bastante significativo que el PLN crea, especialmente en términos de ganancias de eficiencia y precisión diagnóstica. Los sistemas de PLN bien implementados pueden ayudar a reducir la carga administrativa sobre los especialistas sanitarios, aumentar la precisión de los diagnósticos a través de la extracción y análisis de datos relevantes, y mejorar la comunicación entre pacientes y proveedores de servicios de salud [20].

II. MÉTODO DE INVESTIGACIÓN

2.1. Método de Investigación

El propósito principal de este estudio consiste en examinar y contrastar las estrategias de procesamiento de lenguaje natural (PLN) utilizadas en el sector de la salud, con el fin de valorar su influencia en la optimización de procedimientos y prestaciones médicas. Con el propósito de abordar este objetivo, se han planteado las siguientes interrogantes de investigación:

PI1: ¿Cuáles son las técnicas de procesamiento de lenguaje natural más utilizadas en el ámbito sanitario para la mejora de procesos y servicios médicos?

PI2: ¿Cómo impactan las técnicas de PLN en la calidad y eficiencia de los procesos clínicos, como la gestión de historias clínicas y la toma de decisiones médicas?

PI3: ¿Cuáles son los desafíos y limitaciones asociados con la implementación de las técnicas de PLN en el sector sanitario?

La evaluación se realiza a través de un enfoque metodológico de revisión sistemática según las líneas que establece el protocolo PRISMA 2020 [21]. Podemos realizar de esta manera un trabajo detallado y minucioso sobre la literatura acerca del tema cumpliendo con la reconciliación de los criterios de inclusión y/o exclusión de los estudios seleccionados. La metodología PRISMA se ha visto ampliamente justificada ya que permite realizar una evaluación coherente y exacta de las revisiones sistemáticas de los estudios pertinentes, minimizando sesgos y mejorando la calidad del análisis.

Fuentes de información

Para seleccionar los estudios relevantes, se utilizaron las dos bases de datos IEEE Xplore y ScienceDirect, que son fuentes bien conocidas en las áreas de ingeniería informática y salud. Con estas bases de datos, es posible acceder a una amplia variedad de publicaciones revisadas por pares que abordan tanto los marcos teóricos como las aplicaciones prácticas de las tecnologías de procesamiento de lenguaje natural en el cuidado de la salud.

2.2. Plan de investigación

Para el presente trabajo de investigación, se ha optado por un diseño metodológico que en su desarrollo respeta el protocolo PRISMA 2020 [21]. La relevancia del enfoque mencionado radica en la evidencia que garantiza la imparcialidad, confiabilidad y autenticidad de los resultados obtenidos, lo cual es crucial en lo que respecta a la transparencia y consistencia de la evaluación de las estrategias de procesamiento del lenguaje implementadas dentro del dominio de la salud. El método PRISMA ha sido sometido, para fines de su explicación, a tres etapas: Identificación, Filtrado (Screening) e Inclusión.

Identificación

A la presente investigación, en la etapa de Identificación se llevó a cabo una búsqueda exhaustiva de la literatura científica que trató sobre el impacto que tiene el PLN en el ámbito de la salud. Se trató de buscar la mayor cantidad de materiales que se realizaron y que por ser inclusivos debían ajustarse al conjunto de criterios de inclusión preliminarmente establecidos.

Elaboración de la estrategia de búsqueda: Con la intención de obtener información contundente, se elaboraron estrategias de búsqueda consistente en combinar palabras clave tales como "Natural Language Processing in Healthcare", "NLP applications in medical services", y "impact of NLP in healthcare" en algunas de las bases de datos académicas pertinentes. Para la realización de este análisis se seleccionaron las bases de datos IEEE Xplore y ScienceDirect, debido a que son las más completas en informática y en salud.

Realización de la búsqueda: En las bases de datos anteriores se realizó una búsqueda filtrando artículos entre el año 2017 al 2024. Esto garantizó que la información contenida en los textos ayudara a conocer el estado de la investigación sobre el PLN dirigido al área de la salud.

Registro de resultados: Se registraron todos los datos obtenidos en la investigación tales como el título de los estudios, los resúmenes y las citas correspondientes.

Filtrado (Screening)

A lo largo de este proceso, a modo de inclusión, se optó por realizar una selección minuciosa que tomara en cuenta tanto la relevancia como la calidad de los documentos que se habían recopilado. La realización de esta actividad fue desagregada en dos sub-fases: examen de los encabezados y resúmenes y lectura exhaustiva de los documentos completos.

Examen de títulos y resúmenes: Todos los artículos identificados fueron seleccionados utilizando títulos y resúmenes para determinar qué artículos no cumplían con los criterios de inclusión, como aquellos que no trataban sobre la aplicación de PLN en entornos clínicos o cómo tales técnicas mejoraban los procesos de entrega de servicios clínicos y de salud.

Evaluación de textos completos: Los estudios que pasaron el examen inicial fueron revisados en su totalidad para determinar su cumplimiento con los criterios de inclusión específicos establecidos en el protocolo de revisión. Esta evaluación incluyó la evaluación de los métodos utilizados, los resultados obtenidos en relación con los servicios de salud o la atención médica, y la relevancia de los resultados en este ámbito.

Inclusión

La fase de la Inclusión se concibió en el sentido de elegir los estudios finales que serían utilizados en el análisis y síntesis de resultados. Este paso es clave, al igual que en cualquier decisión, para incluir solo los estudios más relevantes y rigurosos en la revisión sistemática.

Extracción de datos: Entre los análisis complementarios incluidos, se trabajaron con muchos elementos clave de datos, como las características del estudio, las técnicas específicas de PLN utilizadas, los resultados y la calidad de la investigación. Esta extracción de datos sentó una base sólida para el resto de las comparaciones y análisis.

Evaluación de calidad: Se realizó una evaluación de la calidad metodológica de cada estudio mediante el uso de estimadores y pruebas de significación que

son estándares en revisiones sistemáticas, como AMSTAR o la escala de Jadad, lo que permitió autenticar la solidez de los resultados reportados.

Síntesis de resultados: Por último, los datos extraídos de los estudios incluidos fueron integrados y analizados en función de su probable contribución a la mejora de procesos y servicios en el sector salud. La síntesis se llevó a cabo mediante una combinación de análisis cualitativo y cuantitativo con el objetivo de obtener una buena visión general de cuáles son las técnicas de NLP más efectivas en ese contexto.

Estas tres etapas - identificación, filtrado e inclusión - garantizan que el proceso de revisión sistemática, o estudio, sea exhaustivo, explícito y metodológicamente sólido, aumentando así la fiabilidad y validez de las conclusiones del estudio.

2.3. Procedimiento de investigación

Identificación de artículos científicos

El 5 de diciembre de 2024 se llevó a cabo la exploración bibliométrica para la revisión sistemática referida a las técnicas de PLN y su uso en el área de la salud. Luego de esto, las publicaciones realizadas por otros investigadores pudiesen contribuir mayor cantidad de artículos publicados, lo cual sería reflejo del desarrollo y dinamismo del área. Se elaboraron las fórmulas de búsqueda (se relacionan en la Tabla 1), con tanto esmero, para asegurar que todos los estudios relevantes sobre el efecto del Procesamiento de Lenguaje Natural en los servicios y procesos de salud están cubiertos en la búsqueda. Debido a la complejidad de las diferentes disciplinas que fueron parte de la investigación se emplearon vocablos especializados y conectores lógicos para que pudieran tomarse conclusiones exactas y relevantes.

Tabla 1. Palabras Clave usadas en las Bases de Datos

Bases de datos	Ecuación de búsqueda
IEEE Xplore	("Natural Language Processing" AND ("Healthcare" OR "Medical" OR "Health services")) AND ("Impact" OR

	"Improvement") ("Natural Language Processing" AND ("Artificial Intelligence" OR "Machine Learning") AND "Healthcare") AND ("Automation" OR "Diagnostics") ("Natural Language Processing" AND "Clinical Data" AND ("Optimization" OR "Automation") AND "Medical Records") ("Natural Language Processing" AND "Clinical Decision Support" AND ("Impact" OR "Efficiency"))
ScienceDirect	("Natural Language Processing" AND ("Clinical Systems" OR "Healthcare Applications")) AND ("Optimization" OR "Automation") ("Natural Language Processing" AND "Health services" AND "Clinical decision support") AND ("Impact" OR "Evaluation") ("Natural Language Processing" AND ("Patient Care" OR "Medical Services") AND ("Improvement" OR "Efficiency")) ("Artificial Intelligence" AND "Natural Language Processing" AND ("Health Technology" OR "Healthcare IT") AND ("Impact" OR "Diagnosis"))
Scopus	("Natural Language Processing" AND ("Medical" OR "Health systems")) AND ("Impact" OR "Improvement") AND NOT ("Linguistics") ("Natural Language Processing" AND

	("Health Information Systems" OR "Clinical Systems") AND "Impact" AND ("Automation" OR "Efficiency")) ("Natural Language Processing" AND "Healthcare" AND "Electronic Health Records" AND ("Improvement" OR "Optimization"))
--	--

Una vez que se realizaron las búsquedas mencionadas, se aplicaron dos criterios de filtrado: fechas (publicaciones entre 2017 y 2024) y tipo de documento (artículos de revistas y conferencias, informes de investigación y capítulos de libros), con el fin de encontrar los estudios más recientes y pertinentes disponibles. Inicialmente, el número total de artículos recuperados fue 328 y esta cifra fue luego reducida tras la selección de los estudios en términos de su relevancia, enfoque utilizado y calidad de la investigación descrita en el artículo. La selección definitiva de los artículos fue, por lo tanto, en función de su relevancia y calidad de la evaluación. También se justificó la preferencia de los estudios que incluían la comparativa entre distintas técnicas de PLN aplicadas en el área de salud, e intentaron explicar cómo estas ayudaban a mejorar ciertos procesos de medicina, tales como la mejora del diagnóstico, la reducción de la entrada manual de documentación médica y la mejora de la calidad del servicio al cliente. [22]

Screening

Se han escogido cuidadosamente los artículos científicos para este análisis exhaustivo, priorizando aquellos que han sido publicados en revistas y conferencias reconocidas que figuran en las prestigiosas bases de datos de IEEE Xplore, ScienceDirect y Scopus, siguiendo los criterios establecidos con antelación. Se ha contemplado la posibilidad de incorporar artículos en diversos idiomas, siempre y cuando los metadatos estén adecuadamente traducidos al inglés, asegurando la coherencia en la presentación y la accesibilidad a la información. Adicionalmente, se llevó a cabo una revisión cronológica meticulosa

que comprendió publicaciones desde el año 2017 hasta el presente (2024), con el propósito de incorporar toda la literatura pertinente que se alinea con los objetivos de la investigación. [23]

Con el objetivo de asegurar la excelencia y pertinencia de los artículos elegidos, se establecieron tres etapas de exclusión, las cuales se describen en la Tabla 2. En la etapa inicial, se eliminaron todos los datos que tenían fallos en la indexación, tales como los que no estaban debidamente etiquetados en cuanto al PLN el campo de la salud. En la etapa siguiente, se dejaron de lado las evaluaciones sistemáticas, dado que se habían identificado previamente como componentes fundamentales para la recopilación. En la etapa conclusiva del análisis, se descartaron las investigaciones que no se enfocaban exclusivamente en la implementación de métodos de procesamiento de lenguaje natural en el ámbito de la salud. Quienes exploraban el estudio del Procesamiento del Lenguaje Natural en campos como la lingüística o la industria del entretenimiento, y cuyo propósito no estuviera centrado en la optimización de servicios médicos y procesos. [24]

Tabla 2. Criterios de inclusión y exclusión

Fase	Criterios de inclusión	Criterios de exclusión
Fase 1	Registros con indización incorrecta	Se descartan artículos que no están correctamente etiquetados o indizados en relación con el PLN o el ámbito sanitario.
Fase 2	Revisiones sistemáticas	Las revisiones sistemáticas ya han sido consideradas como parte de la base de datos para la recopilación de información.

Fase 3	Artículos que no se centran en el PLN dentro del ámbito sanitario (ej., lingüística, entretenimiento)	Se excluyen estudios que no aplican PLN en contextos médicos, como aquellos relacionados con la lingüística o el entretenimiento.
--------	---	---

Elementos de los datos

La Figura 9 sintetiza el diseño metodológico empleado en esta investigación, ilustrando claramente el proceso seguido en la revisión sistemática sobre el impacto de las técnicas de PLN en el ámbito sanitario. El diagrama de flujo muestra las etapas secuenciales que garantizan la validez y confiabilidad de los resultados obtenidos.

Figura 9. Diagrama de flujo PRISMA. Elaboración propia.

